

Przedmiot: **Rozpoznawanie i przetwarzanie obrazów**  
Temat: Miary oceny klasyfikatorów

---

dr inż. Andrzej Burda  
[a.burda@vizja.pl](mailto:a.burda@vizja.pl)

# Statystyki klasyfikacyjne - macierz pomyłek (klasyfikatory binarne)

- ❑ W uczeniu maszynowym najczęściej mamy do czynienia z modelami do klasyfikowania obiektów.
- ❑ Aby stworzyć taki model, to zbiór przypadków uczących musi zawierać atrybut decyzyjny, informację o klasie obiektów w zbiorze przypadków uczących.

dokładność klasyfikacji (ang. <i>accuracy</i> <b>ACC</b> ) $ACC = (TP + TN) / (P + N)$		Klasa predykowana	
		Klasyfikacja pozytywna	Klasyfikacja negatywna
Klasa rzeczywista	Stan Pozytywny <b>P</b>	prawdziwie dodatnia, <b>TP</b>	fałszywie ujemna ( <u>błąd drugiego rodzaju</u> , <b>FN</b> )
	Stan Negatywny <b>N</b>	fałszywie dodatnia ( <u>błąd pierwszego rodzaju</u> , <b>FP</b> )	prawdziwie ujemna, <b>TN</b>

## Miary oceny klasyfikacji

- Czułość** (ang. *sensitivity*, *Recall*, *True Positive Rate TPR*) wskazująca w jakim procencie klasa faktycznie pozytywna została pokryta przewidywaniem pozytywnym.  
 Przykład: jaki procent osób z oceną dobrą model zakwalifikował do klasy dobrych kredytobiorców.

$$TPR = \frac{TP}{P} = \frac{TP}{TP + FN}$$

- Specyficzność** (ang. *specificity SPC*, *True Negative Rate TNR*) wskazująca w jakim procencie klasa faktycznie negatywna została pokryta przewidywaniem negatywnym.  
 Przykład: jaki procent osób z oceną złą model zakwalifikował do klasy złych kredytobiorców.

$$TNR = \frac{TN}{N} = \frac{TN}{FP + TN}$$

dokładność klasyfikacji (ang. <i>accuracy ACC</i> ) $ACC = (TP + TN) / (P + N)$		Klasa predykowana	
		Klasyfikacja pozytywna	Klasyfikacja negatywna
Klasa rzeczywista	Stan Pozytywny P	prawdziwie dodatnia, TP	fałszywie ujemna ( <u>błąd drugiego rodzaju</u> , FN)
	Stan Negatywny N	fałszywie dodatnia ( <u>błąd pierwszego rodzaju</u> , FP)	prawdziwie ujemna, TN

## Miary oceny klasyfikatora

- ❑ **Precyzja pozytywna** (ang. *precision, Positive Predictive Value PPV*) informuje o stopniu pewności klasyfikacji jeśli wynik klasyfikacji jest pozytywny.

$$PPV = \frac{TP}{TP + FP}$$

- ❑ **Precyzja negatywna** (ang. *Negative Predictive Value NPV*) informuje o stopniu pewności klasyfikacji jeśli wynik klasyfikacji jest negatywny.

$$NPV = \frac{TN}{TN + FN}$$

dokładność klasyfikacji (ang. <i>accuracy ACC</i> ) $ACC = (TP + TN) / (P + N)$		Klasa predykowana	
		Klasyfikacja pozytywna	Klasyfikacja negatywna
Klasa rzeczywista	Stan Pozytywny P	prawdziwie dodatnia, TP	fałszywie ujemna ( <u>błąd drugiego rodzaju</u> , FN)
	Stan Negatywny N	fałszywie dodatnia ( <u>błąd pierwszego rodzaju</u> , FP)	prawdziwie ujemna, TN

# Zależności pomiędzy miarami jakości klasyfikacji

- ❑ **Czułość** (*Recal*) i **Specyficzność** (*Specificity*) teoretycznie są niezależne. W praktyce jednak zwiększanie czułości prowadzi często do zmniejszenia specyficzności.
- ❑ **Precyzja pozytywna** (*Precision*) i **Precyzja negatywna** (*NPV*) są miarami mocno od siebie zależnymi. Przykładowo, zwiększając frakcję TP zmniejszamy frakcję FN, lub zmniejszając frakcję FP zwiększamy frakcję TN.

dokładność klasyfikacji (ang. <i>accuracy ACC</i> ) $ACC=(TP+TN)/(P+N)$		Klasa predykowana	
		Klasyfikacja pozytywna	Klasyfikacja negatywna
Klasa rzeczywista	Stan Pozytywny <b>P</b>	prawdziwie dodatnia, <b>TP</b>	fałszywie ujemna ( <u>błąd drugiego rodzaju</u> , <b>FN</b> )
	Stan Negatywny <b>N</b>	fałszywie dodatnia ( <u>błąd pierwszego rodzaju</u> , <b>FP</b> )	prawdziwie ujemna, <b>TN</b>

- ❑ Wcześniej rozważane miary były sparowane, tzn. trzeba obie jednocześnie brać pod uwagę przy ocenie testu/klasyfikatora. Poniżej są definicje popularnych miar sprowadzonych do jednej liczby, która w pewnym stopniu opisuje całościowo wyniki klasyfikacji.

- ❑ Wspomniana już na samym początku **Dokładność klasyfikacji**:  $ACC = \frac{TP+TN}{P+N}$


- ❑ Powiązany z nią **Błąd klasyfikacji**:  $Err = \frac{FP+FN}{P+N}$ ,  $Err = 1 - ACC$  **Zależność nie zawsze prawdziwa**

- ❑ **Współczynnik korelacji Matthews'a** (ang. *Matthews Correlation Coefficient*):

$$MCC = \frac{TP * TN - FP * FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

- ❑ Współczynnik ten uwzględnia wyniki zarówno prawdziwie jak i fałszywie pozytywne i negatywne i jest na ogół uważany jako zrównoważona miara, która może być stosowana nawet wtedy, gdy klasy są bardzo różnej liczebności. *MCC* jest w istocie współczynnikiem korelacji pomiędzy obserwowanymi i przewidywanymi klasyfikacjami binarnymi; zwraca wartość od -1 do +1. Współczynnik +1 odpowiada idealnej klasyfikacji, 0 nie lepiej niż losowe przypisanie wyniku -1 oznacza całkowicie niezgodną klasyfikacją ze stanem faktycznym.

# Miejsce na gromadzenie metryk oceny modelu

 ZMSI\_L9\_AB.ipynb ☆

Plik Edytuj Widok Wstaw Środowisko wykonawcze Narzędzia Pomoc Wszystkie zmiany zostały zapisane

Pliki

ultralytics

animals-1

docker

docs

examples

runs

detect

train

weights

F1\_curve.png

PR\_curve.png

+ Kod + Tekst

building editable for ultralytics (pyproject.com) ... done

2 s

```
# Import przydatnych bibliotek
import torch
from ultralytics import utils
from matplotlib import pyplot as plt
from matplotlib import image
```

[ ] from ultralytics import YOLO

[ ] # Maksymalna wartość punktów za Zad 9.2: 10
punkty.append(10)

▼

**Zad 7.3.** Wytrenuj model z automatycznym zapisem wag najlepszego modelu do pliku

▶

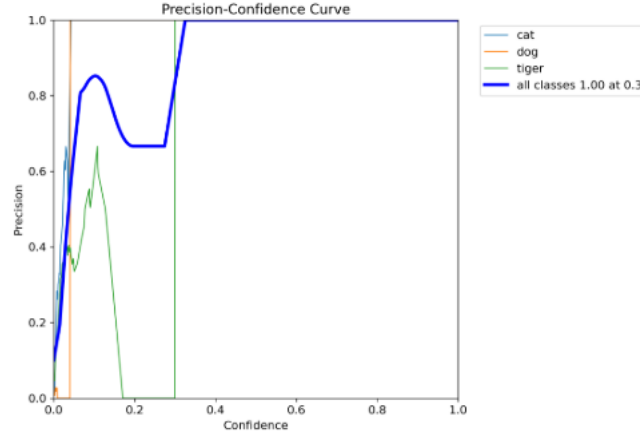
```
# Wczytaj model YOLOv8
yolo_detect = YOLO('yolov8n.pt')
```

T4 Pamięć RAM Dysk

Gemini

PR\_curve.png P\_curve.png X conf ...

Precision-Confidence Curve



Precision

Confidence


cat, dog, tiger, all classes 1.00 at 0.325

08.12.2024

dr inż. Andrzej Burda

7 / 13

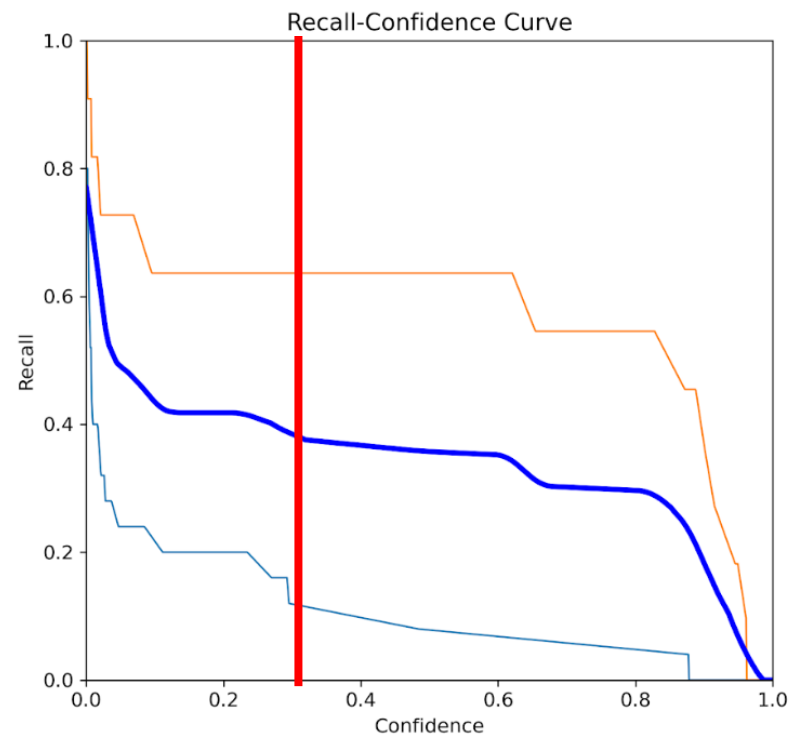
# Precyzja pozytywna (*Precision*)



- ☐ Jeśli uruchomimy detekcję przy  $\text{conf}=0.3$ , to:
  - ☐ pewność klasyfikacji wyniesie  $P \sim 0.6$
  - ☐ pewność klasyfikacji dla kotów wyniesie  $P=1$
  - ☐ pewność klasyfikacji dla psów wyniesie  $P \sim 0.22$
- ☐ Psy i koty, które rozpoznawane są z prawdopodobieństwem mniejszym niż 0.3 nie będą oznaczane/klasyfikowane.


```
yolo_detect = YOLO('yolov8n.pt')  
results_detect = yolo_detect(['/content/ultralytics/test2-1/train/images/1.jpg',  
                               'rf.2c1336181496cf0f4cae5f38f14d7c88.jpg'], conf=0.30)
```





- ❑ Jeśli uruchomimy detekcję przy  $\text{conf}=0.3$ , to:
  - ❑  $\sim 0.4$  obrazów zostanie właściwie sklasyfikowanych
  - ❑  $\sim 0.15$  kotów zostanie właściwie sklasyfikowanych
  - ❑  $\sim 0.65$  psów zostanie właściwie sklasyfikowanych
  - ❑ Pozostałe albo będą niesklasyfikowane albo błędnie sklasyfikowane.

```
yolo_detect = YOLO('yolov8n.pt')  
results_detect = yolo_detect(['/content/ultralytics/test2-1/train/images/1_jpg.rf.2c1336181496cf0f4cae5f38f14d7c88.jpg'], conf=0.3)
```



- ❑ Wartości średniej precyzji modelu to całkowity obszar pod wykresem, obliczana jako uśredniona precyzja dla różnych progów czułości.
- ❑ Im wyższa wartość, tym lepszy model.

- ❑ Kompromis między *Precision* a *Recall*:
  - ❑ Jeśli zależy nam na wysokiej *Precision* (np. w krytycznych aplikacjach), akceptujemy niższy *Recall*.
  - ❑ Jeśli zależy nam na wysokim *Recall* (np. wykrycie każdego podejrzanego obiektu), musimy zaakceptować niższą precyzję.

# Wpływ na wynik detekcji

